

Laporan Tugas Praktikum 09



Muhammad Bintang Gunawan - 0110224003

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

0110224003@student.nurulfikri.ac.id

Abstract

Inti dari praktikum ini adalah menguji coba dan menilai kehebatan algoritma Naive Bayes (jenis GaussianNB) dalam melakukan klasifikasi. Kita akan memprediksi jenis tumor, apakah itu **jinak** atau **ganas**, hanya dengan melihat ciri-ciri bentuk selnya.

1. Interpretasi Hasil Pra-pemrosesan:

- Pembersihan Data: Kolom identitas (id) dan kolom kosong yang tidak relevan berhasil dihapus, meninggalkan 31 fitur dan 569 sampel data.
- Keseimbangan Kelas: Setelah *encoding* kategori (M1, B0), data menunjukkan distribusi yang cukup seimbang, dengan 357 kasus Benign dan 212 kasus Malignant. Keseimbangan ini meminimalkan risiko bias model terhadap satu kelas.
- Pengecekan Outlier: Visualisasi *boxplot* menunjukkan keberadaan *outlier* pada banyak fitur (misalnya radius_mean dan area_mean), yang menguatkan keputusan untuk menggunakan StandardScaler untuk menstandarisasi data.

Tampilan Code & hasilnya

Pra-pemrosesan Data

```
df_cancer = df_cancer.drop(columns=['id', df_cancer.columns[-1]])
print(df_cancer.shape)

(569, 31)
```

```
d
print("Missing values per column:")
print(df_cancer.isnull().sum())
```

```
Missing values per column:
diagnosis          0
radius_mean       0
texture_mean      0
perimeter_mean    0
area_mean         0
smoothness_mean   0
compactness_mean  0
concavity_mean    0
concave_points_mean 0
symmetry_mean     0
fractal_dimension_mean 0
radius_se         0
texture_se        0
perimeter_se      0
area_se          0
smoothness_se     0
compactness_se    0
concavity_se      0
concave_points_se 0
symmetry_se       0
fractal_dimension_se 0
radius_worst      0
texture_worst     0
perimeter_worst   0
area_worst        0
smoothness_worst  0
compactness_worst 0
concavity_worst   0
concave_points_worst 0
symmetry_worst    0
fractal_dimension_worst 0
dtype: int64
```


```
Encoding Kategorikal

[19] df_cancer['diagnosis'].replace({'M': 1, 'B': 0}, inplace=True)
print("\nValue Counts for Diagnosis (Encoded):")
print(df_cancer['diagnosis'].value_counts())

Value Counts for Diagnosis (Encoded):
diagnosis
0    357
1    212
Name: count, dtype: int64

/tmp/ipython-input-2924780779.py:2: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the
df_cancer['diagnosis'].replace({'M': 1, 'B': 0}, inplace=True)
/tmp/ipython-input-2924780779.py:2: FutureWarning: Downcasting behavior in 'replace' is deprecated and will be removed in a future version. To retain the old behavior, explicitly call 'result.infer
df_cancer['diagnosis'].replace({'M': 1, 'B': 0}, inplace=True)
```



2. Implementasi Model dan Skala Data

Model yang digunakan adalah Gaussian Naive Bayes (GaussianNB), yang mengasumsikan fitur-fitur input terdistribusi secara normal.

Langkah	Rincian Implementasi	Tujuan
Pemisahan Data	Fitur (X) dipisahkan dari Target (Y: diagnosis).	Memisahkan variabel independen (fitur) dari variabel dependen (target).
Pembagian Data	Data dibagi menjadi 80% Latih (455 data) dan 20% Uji (114 data), dengan stratify=Y.	Menyiapkan set data yang independen untuk pelatihan dan pengujian, serta memastikan rasio kelas (M:B) tetap terjaga di kedua set.
Penskalaan Data	StandardScaler diterapkan pada data latih dan uji.	Menstandarisasi fitur (mean=0, std=1), yang krusial bagi GaussianNB agar asumsi distribusi normalnya terpenuhi, sehingga meningkatkan stabilitas dan performa model.

Memisahkan Fitur (X) dan Target (Y)

```
[20]
✓ 0 d X = df_cancer.drop(columns=['diagnosis'])
      Y = df_cancer['diagnosis']
      print(X.shape, Y.shape)
```

▼ (569, 30) (569,)

Pembagian Data (Train-Test Split)

```
[21]
      from sklearn.model_selection import train_test_split

      X_train, X_test, Y_train, Y_test = train_test_split(
          X, Y, test_size=0.2, stratify=Y, random_state=42
      )
      print(X_train.shape, X_test.shape)
```

▼ (455, 30) (114, 30)

Scaling

```
[22]
✓ 0 d ▶ from sklearn.preprocessing import StandardScaler

      scaler = StandardScaler()
      # Melatih scaler pada data training dan menerapkannya
      X_train_scaled = scaler.fit_transform(X_train)
      # Menerapkan scaler pada data testing
      X_test_scaled = scaler.transform(X_test)
```

3. Interpretasi Hasil Evaluasi Model & Classification Report

Model GaussianNB dilatih menggunakan data latih yg sudah diskalakan dan diuji pda data uji.

```
Accuracy Score

26] 0 d
print("Training Accuracy (NB):", accuracy_score(Y_train, train_pred_nb))
print("Testing Accuracy (NB):", accuracy_score(Y_test, test_pred_nb))

Training Accuracy (NB): 0.945054945054945
Testing Accuracy (NB): 0.9210526315789473

Classification Report

27] 0 d
from sklearn.metrics import classification_report

print("\nClassification Report (NB) on Test Data:")
print(classification_report(Y_test, test_pred_nb, target_names=['Benign (0)', 'Malignant (1)']))

Classification Report (NB) on Test Data:
      precision    recall  f1-score   support

 Benign (0)       0.92      0.96      0.94         72
 Malignant (1)    0.92      0.86      0.89         42

 accuracy          0.92
 macro avg         0.92
 weighted avg      0.92
```

```
Cross-Validation

from sklearn.model_selection import cross_val_score
import numpy as np

cv_nb = cross_val_score(nb_model, X, Y, cv=5, scoring='accuracy')

print("\nNaive Bayes Cross Validation Accuracy (5-Fold):")
print("Scores:", cv_nb)
print("Mean Accuracy:", cv_nb.mean())
print("Std Deviation:", cv_nb.std())

Naive Bayes Cross Validation Accuracy (5-Fold):
Scores: [0.92105263 0.92105263 0.94736842 0.94736842 0.95575221]
Mean Accuracy: 0.9385188635305075
Std Deviation: 0.014585994424363306
```


4. Confusion Matrix

Aktual / Prediksi	Benign (0)	Malignant (1)
Benign (0)	71 (True Negatives)	1 (False Positive)
Malignant (1)	8 (False Negative)	34 (True Positives)

```
from sklearn.metrics import confusion_matrix
import matplotlib.pyplot as plt
import seaborn as sns

cm_nb = confusion_matrix(Y_test, test_pred_nb)

plt.figure(figsize=(6, 4))
sns.heatmap(
    cm_nb,
    annot=True,
    fmt="d",
    cmap="Blues",
    xticklabels=['Benign (0)', 'Malignant (1)'],
    yticklabels=['Benign (0)', 'Malignant (1)']
)
plt.title("Confusion Matrix - Gaussian Naive Bayes on Cancer Data")
plt.xlabel("Predicted")
plt.ylabel("Actual")
plt.show()
```



5. Kesimpulan

Secara keseluruhan, model kita akurat banget. Namun, kita tidak bisa mengabaikan 8 kasus False Negative ini artinya model gagal mendeteksi 8 tumor ganas dan menganggapnya jinak. Dalam dunia nyata, hasil ini sangat membantu sebagai alat *screening* awal, tapi ingat, keputusan akhir (diagnosis) wajib diambil setelah analisis medis yang lebih mendalam.

Link GitHub:

https://github.com/XiaoMao15/ML_Praktikum-dan-Tugas.git